


CNN_pytorch_cifar100



GPU 사용 설정

```
device = 'cuda' if torch.cuda.is_available() else 'cpu'  
torch.manual_seed(777)  
if device == 'cuda':  
    torch.cuda.manual_seed_all(777)  
print(device + " is available")
```

CUDA가 있으면 device = 'cuda'로 설정해서 언제든지 gpu를 사용할 수 있게 만들어줌

데이터셋 로드

```
cifar_train = torchvision.datasets.CIFAR100(root='.',  
                                             train=True,  
                                             transform=transforms.ToTensor(),  
                                             download=True)  
  
cifar_test = torchvision.datasets.CIFAR100(root='.',  
                                             train=False,  
                                             transform=transforms.ToTensor(),  
                                             download=True)  
  
# Load CIFAR-100 dataset  
train_dataloader = torch.utils.data.DataLoader(dataset=cifar_train,  
                                                batch_size=batch_size,  
                                                shuffle=True,  
                                                drop_last=True)  
  
test_dataloader = torch.utils.data.DataLoader(dataset=cifar_test,  
                                               batch_size=batch_size,  
                                               shuffle=True,  
                                               drop_last=True)
```

root = cifar 데이터셋을 저장할 경로

train : True로 설정 시 trainset, False로 설정시

test set을 불러옴

download = True로 설정시 인터넷에서 데이터셋

다운로드

transform = 데이터셋을 불러온 후 어떤 전처리를

할지 설정

여기서는 ToTensor()함수를 사용하여 0~255를

0~1로 변환

import

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
import torchvision
import torchvision.transforms as transforms
```

torch : pytorch의 기본 패키지, tensor 연산 및 딥러닝 모델 구현에 필요한 함수들을 제공

torch.nn : 신경망 모델을 구현하기 위한 클래스와 함수들이 들어있는 모듈

torch.nn.functional : 신경망 모델에서 자주 사용하는 함수

torch.optim : 경사하강법등 최적화 알고리즘 제공

torchvision : 이미지 및 비디오 처리를 위한 패키지

torchvision.transforms : 이미지 변환을 위한 함수

데이터 불러오기

```
# Load CIFAR-100 dataset
train_dataloader = torch.utils.data.DataLoader(dataset=cifar_train,
                                                batch_size=batch_size,
                                                shuffle=True,
                                                drop_last=True)

test_dataloader = torch.utils.data.DataLoader(dataset=cifar_test,
                                              batch_size=batch_size,
                                              shuffle=True,
                                              drop_last=True)
```

torch.utils.data.DataLoader = 미리 정의된 batch size로 train_set과 test_set을 load함

root = cifar 데이터셋을 저장할 경로

train : True로 설정 시 trainset, False로 설정시

test set을 불러옴

download = True로 설정시 인터넷에서 데이터셋 다운로드

transform = 데이터셋을 불러온 후 어떤 전처리를 할지 설정

여기서는 ToTensor()함수를 사용하여 0~255를 0~1로 변환

기본 파라미터 값 설정

```
# CIFAR-100 데이터셋 불러오기  
learning_rate = 0.001  
training_epochs = 20  
batch_size = 128
```

학습률 : 알고리즘에서 가중치를 업데이트 할때 사용되는 스칼라 값. 학습률이 작을수록 가중치 업데이트가 느리게 이루어짐

배치사이즈 : 학습데이터를 학습할때 미니 배치의 크기

num_classes : 분류하고자 하는 클래스 개수

epochs : 전체 학습 데이터셋을 몇번 반복할 것인지

ConvNet class __init__

```
class Net(nn.Module):  
    def __init__(self):  
        super(Net, self).__init__()  
        self.layer1 = torch.nn.Sequential(  
            torch.nn.Conv2d(3, 32, (3,3), padding='same'),  
            torch.nn.ReLU(),  
            torch.nn.BatchNorm2d(32),  
            torch.nn.MaxPool2d((2,2)),  
            torch.nn.Dropout(0.5)  
        )  
        self.layer2 = torch.nn.Sequential(  
            torch.nn.Conv2d(32, 64, (3,3), padding='same'),  
            torch.nn.ReLU(),  
            torch.nn.BatchNorm2d(64),  
            torch.nn.MaxPool2d((2,2)),  
            torch.nn.Dropout(0.5)  
        )
```

1. `in_channels` (int): 입력 이미지의 채널 수
2. `out_channels` (int): 출력 이미지의 채널 수 (필터의 개수)
3. `kernel_size` (int 또는 Tuple[int, int]): 컨볼루션 커널의 크기
4. `stride` (int 또는 Tuple[int, int]): 컨볼루션 연산 시 필터의 이동 간격
5. `padding` (int 또는 Tuple[int, int]): 입력 이미지 주변에 추가할 패딩 크기
6. `dilation` (int 또는 Tuple[int, int]): 컨볼루션 커널 내부의 간격
7. `groups` (int): 입력 채널을 나누어 여러 그룹으로 컨볼루션 연산을 수행할 때 그룹 수
8. `bias` (bool): 편향(bias) 사용 여부

class ConvNet은 nn.Module 클래스를 상속받아 정의됨, nn.Module 클래스는 pytorch에서 제공하는 모든 신경망 모듈의 기본 클래스

Conv2d 함수를 다섯번 작성, maxpool 작성, Linear 3개작성, dropout작

출력 크기 계산 공식

$$O = \frac{I - K + 2P}{S} + 1$$

1. 입력 이미지의 크기를 $W \times W$ 라 가정합니다.
2. 필터(커널)의 크기를 $K \times K$ 라 가정합니다.
3. 패딩의 크기를 P 라 가정합니다.
4. 스트라이드 값(필터를 이동시키는 간격)을 S 라 가정합니다.
5. 합성곱 연산을 수행하면 필터와 입력 이미지가 겹치는 부분에서 곱셈한 결과를 모두 더한 값이 출력 이미지의 한 픽셀에 대응합니다.
6. 입력 이미지의 한 픽셀을 중심으로 필터를 이동시키는 경우, 이동할 수 있는 범위는 $(W-K+1) \times (W-K+1)$ 입니다.
7. 하지만 이동할 수 있는 범위가 출력 이미지의 크기와 일치하지 않을 수 있습니다. 따라서, 이동할 수 있는 범위에서 출력 이미지의 크기에 해당하는 부분만 잘라내어 사용합니다.
8. 출력 이미지의 크기를 $H \times H$ 라 가정합니다.
9. 이 때, 이동할 수 있는 범위에서 출력 이미지의 크기에 해당하는 부분은 $(H-1) \times (H-1)$ 이므로, $(W-K+1) \times (W-K+1) = (H-1) \times (H-1)$ 입니다.
10. 이를 정리하면, $H = ((W-K+1) - 1) / S + 1$ 이 됩니다.
11. 하지만 이 공식에 패딩을 추가할 수도 있습니다. 패딩을 P 만큼 추가하면, 입력 이미지의 크기는 $(W+2P) \times (W+2P)$ 가 됩니다.
12. 이 경우, 출력 이미지의 크기를 $H \times H$ 라 가정하면, $(W+2P-K+1) \times (W+2P-K+1) = (H-1) \times (H-1)$ 입니다.
13. 이를 정리하면, $H = ((W+2P-K+1) - 1) / S + 1$ 이 됩니다.
14. 따라서, $((W-K+2P)/S)+1$ 공식이 유도됩니다.

```
self.conv1 = nn.Conv2d(1, 10, kernel_size=5) # input channel = 1, filter = 10, kernel size = 5, zero padding = 0, stride = 1
# ((W-K+2P)/S)+1 공식으로 인해 ((28-5+0)/1)+1=24 -> 24x24로 변환
```

```
self.conv2 = nn.Conv2d(10, 20, kernel_size=5) # input channel = 1, filter = 10, kernel size = 5, zero padding = 0, stride = 1
# ((12-5+0)/1)+1=8 -> 8x8로 변환
```

출력 크기 = ((입력 크기 - 필터 크기 + 2*
패딩) / 스트라이드) + 1

Conv2D (패딩)

0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

Kernel		
0	-1	0
-1	5	-1
0	-1	0

114				

padding이 same인 경우, 출력 특징맵의 크기가 입력 특징맵의 크기와 상관없이 동일하게 유지됩니다.

3_0	3_1	2_2	1	0
0_2	0_2	1_0	3	1
3_0	1_1	2_2	2	3
2	0	0	2	2
2	0	0	0	1


12.0	12.0	17.0
10.0	17.0	19.0
9.0	6.0	14.0

padding이 valid인 경우 출력 특징맵의 크기는 입력 특징맵의 크기와 필터의 크기에 따라 결정됩니다.

스트라이드를 통해 조절 가능

Conv2D (maxpool2D)

```
x = F.relu(self.mp(self.conv1(x)))  
x = F.relu(self.mp(self.conv2(x)))  
# ...
```




Max Pooling

MaxPool2D 레이어는 입력으로 받은 64개의 28x28 크기의 특징 맵(feature map)에서 2x2 크기의 윈도우(window)를 이동시켜가며 각 윈도우에서 가장 큰 값을 출력으로 반환

입력 특징 맵보다 크기가 반으로 줄어들게 되는데, 이를 통해 계산량을 줄이고, 과적합(overfitting)을 방지하고, 불필요한 정보를 걸러낼 수 있음

Dense>>Linear

```
self.drop2d = nn.Dropout2d(p=0.25, inplace=False) # 랜덤히  
self.mp = nn.MaxPool2d(2) # 오버피팅을 방지하고, 연산에  
self.fc1 = nn.Linear(320,100) # 4x4x20 vector로 flat한 것  
self.fc2 = nn.Linear(100,10) # 100개의 출력을 10개의 출력.
```




`nn.Linear`` 함수는 PyTorch에서 완전 연결 (fully connected) 레이어를 정의하는데 사용됩니다. 이 함수는 입력과 출력의 차원을 인자로 받아 가중치 행렬을 만들고, 입력에 가중치를 곱하고 편향을 더하여 출력을 계산합니다.

예를 들어, ``nn.Linear(10, 5)``는 10차원의 입력을 5차원의 출력으로 변환하는 완전 연결 레이어를 정의합니다. 이 레이어의 가중치 행렬은 크기가 (5, 10)이며, 편향 벡터의 크기는 (5,)입니다.

`==`Dense(5, input_shape=(10,))``

Dropout

```
self.drop2D = nn.Dropout2d(p=0.25, inplace=False) #
```



Dropout`은 딥러닝에서 과적합(overfitting)을 방지하기 위한 regularization 기법 중 하나입니다. `Dropout`은 레이어에 적용되며, 입력값의 일부를 랜덤하게 0으로 만듭니다. 이를 통해 특정 뉴런이 특정 입력값에 의존하는 것을 방지하고, 레이어의 복잡도를 줄여 일반화 성능을 향상시킵니다.

def forward

```
def forward(self, x):  
    x = F.relu(self.mp(self.conv1(x))) # convolution layer 1번에 relu를 씌우고 maxpool, 결과값은 12x12x10  
    x = F.relu(self.mp(self.conv2(x))) # convolution layer 2번에 relu를 씌우고 maxpool, 결과값은 4x4x20  
    x = self.drop2D(x)  
    x = x.view(x.size(0), -1) # flat  
    x = self.fc1(x) # fc1 레이어에 삽입  
    x = self.fc2(x) # fc2 레이어에 삽입  
    return F.log_softmax(x) # fully-connected layer에 넣고 logsoftmax 적용
```

`x = F.relu(self.mp(self.conv1(x)))`: 입력 데이터 `x`를 첫 번째 합성곱 레이어 `self.conv1`을 통해 통과시키고, 그 결과에 ReLU 함수를 적용하고, 맥스 풀링 레이어 `self.mp`를 적용합니다

`x = self.drop2D(x)`: 출력값 `x`에 2D 드롭아웃 레이어 `self.drop2D`를 적용합니다.

`x = x.view(x.size(0), -1)`: 출력값 `x`를 2차원으로 변환합니다. 이는 fully connected 레이어에 입력으로 넣기 위한 과정(Flatten)

`x = self.fc1(x)`: 2차원으로 변환된 출력값 `x`를 첫 번째 fully connected 레이어 `self.fc1`에 입력으로 넣습니다

`return F.log_softmax(x)`: 마지막으로 fully connected 레이어를 통과한 결과값 `x`에 로그 소프트맥스 함수를 적용한 결과를 반환합니다.

Conv2D (activation(relu))

```
def forward(self, x):  
    x = F.relu(self.mp(self.conv1(x))) # convolution layer 1번에 relu를 씌우고 maxpool, 결과값은 12x12x10  
    x = F.relu(self.mp(self.conv2(x))) # convolution layer 2번에 relu를 씌우고 maxpool, 결과값은 4x4x20  
    x = self.drop2D(x)  
    x = x.view(x.size(0), -1) # flat  
    x = self.fc1(x) # fc1 레이어에 삽입  
    x = self.fc2(x) # fc2 레이어에 삽입  
    return F.log_softmax(x) # fully-connected layer에 넣고 logsoftmax 적용
```

ReLU
 $\max(0, x)$



ReLU 함수는 입력값이 0보다 클 때는 선형 함수처럼 작동하지만, 입력값이 0 이하일 때는 항상 0을 출력함

ReLU 함수는 계산 비용이 매우 적게 듦

죽은 뉴런(dead neuron) 현상이 발생할 수 있습니다. 이러한 현상이 발생하면 해당 뉴런은 학습 과정에서 어떠한 역할도 하지 못하게 됨

Adam

```
optimizer = torch.optim.Adam(model.parameters(), lr = learning_rate)
```

이해가... 안됩니다 다음주 안에 추가하겠습니다.



모델 학습 설정

```
model = ConvNet().to(device) # CNN instance 생성  
# Cost Function과 Optimizer 선택  
criterion = nn.CrossEntropyLoss().to(device)  
optimizer = torch.optim.Adam(model.parameters(), lr = learning_rate)
```

`model = ConvNet().to(device)`: `ConvNet` 클래스를 인스턴스화하여 `model` 변수에 저장합니다. 이때 `to(device)` 메서드를 사용하여 모델이 GPU에서 실행되도록 설정합니다.

`criterion = nn.CrossEntropyLoss().to(device)`: 크로스 엔트로피 손실 함수 `nn.CrossEntropyLoss()`를 인스턴스화하여 `criterion` 변수에 저장

`optimizer = torch.optim.Adam(model.parameters(), lr = learning_rate)`: Adam 옵티마이저를 인스턴스화하여 `optimizer` 변수에 저장합니다. `model.parameters()`를 사용하여 모델의 학습 가능한 매개변수들을 전달하고, `lr` 매개변수를 통해 학습률을 설정합니다.

모델 학습 설정(test)

```
def test(dataloader, model, criterion):
    size = len(dataloader.dataset)
    num_batches = len(dataloader)
    model.eval()
    test_loss, test_acc = 0, 0
    with torch.no_grad():
        for X, y in dataloader:
            X, y = X.to(device), y.to(device)
            pred = model(X)
            test_loss += criterion(pred, y).item()
            test_acc += (pred.argmax(1) == y).type(torch.float).sum().item()

    test_loss /= num_batches
    test_acc /= size

    print(f"TEST: \n Accuracy: {(100*test_acc):>.1f}%, Avg loss: {test_loss:>8f} \n")

    return test_loss, test_acc
```

dataset읽어오는 모듈,모델,손실함수
모델을 평가모드로 설정한 후 no_grad()를
사용하여 그래디언트 계산을 비활성화 합니
다. (모델의 파라미터를 업데이트 하는 과정
에서 계산 생략 (평가할때는 필요 X))

그 후 dataloader에서 배치데이터를 읽어오
면서
손실과 정확도를 반환합니다.

X = 입력데이터(batch), y = 정답데이터

모델 학습 설정(train)

```
def train(dataloader, model, criterion, optimizer):  
    size = len(dataloader.dataset)  
    train_accuracy, train_loss = 0, 0  
    model.train()  
    for batch, (X, y) in enumerate(dataloader, 0):  
  
        X, y = X.to(device), y.to(device)  
        optimizer.zero_grad()  
        pred = model(X)  
        loss = criterion(pred, y)  
        loss.backward()  
        optimizer.step()  
  
        train_accuracy += (pred.argmax(1) == y).type(torch.float).sum().item()  
        train_loss += loss.item()  
  
        if batch % 100 == 0:  
            current = (batch+1) * len(X)  
  
            print(f"loss: {train_loss/current:>7f} accuracy: {train_accuracy/current:>7f}")  
  
    return train_loss/len(dataloader), train_accuracy/size
```

dataset 읽어오는 모듈, 모델, 손실함수, 최적화 함

size 변수에 전체 데이터셋의 크기 저장. 그 후 초기화, 그리고 모델을 학습모드로 설정.

입력데이터와 정답데이터를 분배한 후 gpu로 설정, optimizer 기울기 초기화. 그 후 예측 시작 순전파, 역전파 그 후 파라미터 업데이트,

정확도와 손실도 계산 후 배치수가 100의 배수일때마다 손실과 정확도 출력

모델 훈련 후 저장

```
epochs = 10
training_loss, training_accuracy = [], []
validation_loss, validation_accuracy = [], []
for i in range(epochs):
    print("Epoch {}#n-----".format(i+1))
    train_loss, train_accuracy = train(train_loader, model, criterion, optimizer)
    val_loss, val_accuracy = test(test_loader, model, criterion)

    training_loss.append(train_loss)
    training_accuracy.append(train_accuracy)
    validation_loss.append(val_loss)
    validation_accuracy.append(val_accuracy)
history = [training_loss, training_accuracy, validation_loss, validation_accuracy]
PATH_TO_TRAINED_MODEL = 'model.pth'
torch.save(model.state_dict(), PATH_TO_TRAINED_MODEL)
```

epochs 변수설정
train_loss와 train_accuracy
val_loss와 val_accuracy list에 저장 후
history로 묶음

model 저장!!


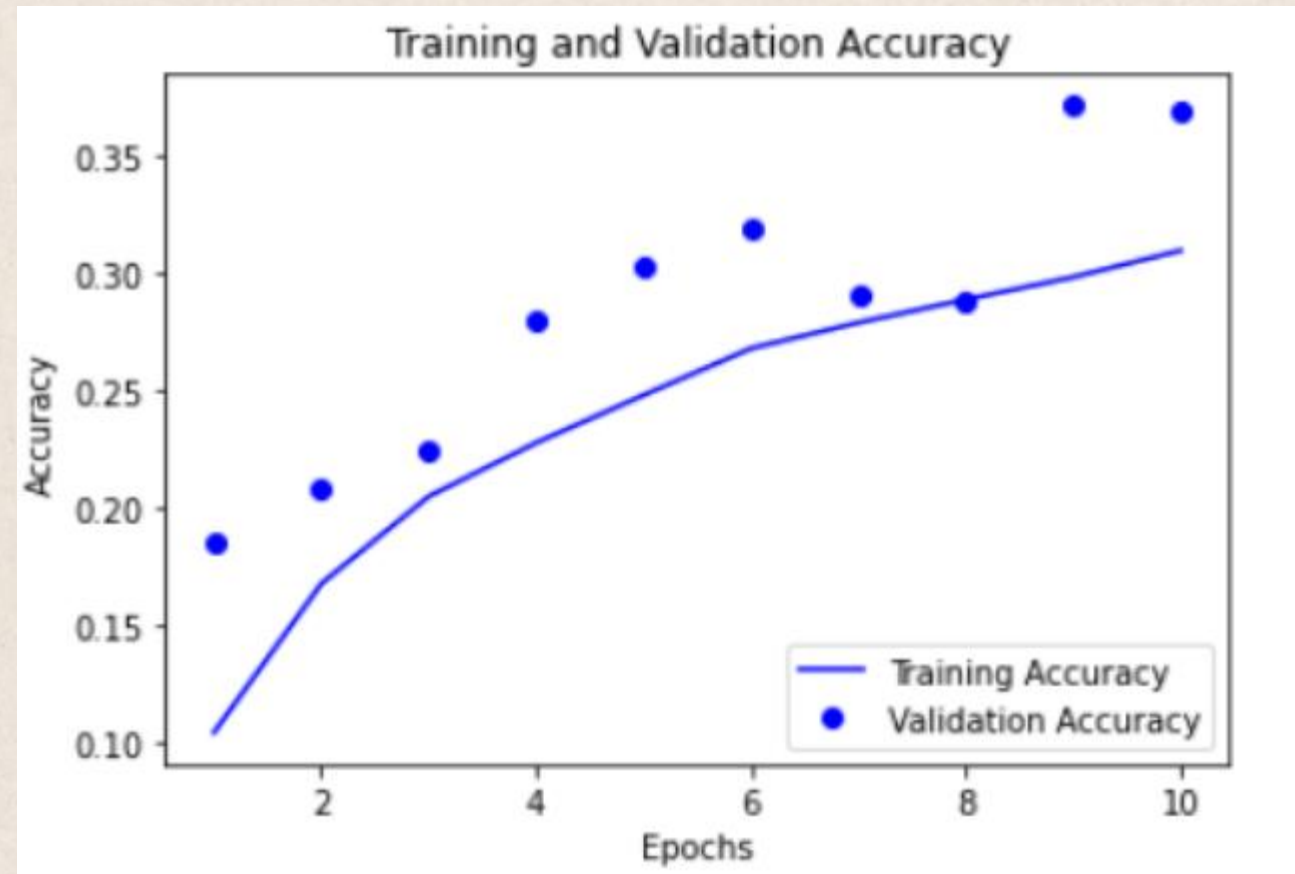
epoch

```
Epoch 9
-----
loss:0.021712 accuracy: 0.281250 [ 128/50000]
loss:0.021682 accuracy: 0.298035 [12928/50000]
loss:0.021737 accuracy: 0.297613 [25728/50000]
loss:0.021741 accuracy: 0.298588 [38528/50000]
TEST:
  Accuracy: 37.2%, Avg loss: 2.432543

Epoch 10
-----
loss:0.019443 accuracy: 0.375000 [ 128/50000]
loss:0.021296 accuracy: 0.311572 [12928/50000]
loss:0.021346 accuracy: 0.308030 [25728/50000]
loss:0.021330 accuracy: 0.308970 [38528/50000]
TEST:
  Accuracy: 37.0%, Avg loss: 2.477928
```

\epoch = 10, Accuracy : 37%, Avg loss : 2.477

accuracy, loss graph



Conv2D (가중치)

```
def forward(self, x):
    x = F.relu(self.mp(self.conv1(x))) # convolution layer 1번에 relu를 씌우고 maxpool, 결과값은 12x12x10
    x = F.relu(self.mp(self.conv2(x))) # convolution layer 2번에 relu를 씌우고 maxpool, 결과값은 4x4x20
    x = self.drop2D(x)
    x = x.view(x.size(0), -1) # flat
    x = self.fc1(x) # fc1 레이어에 삽입
    x = self.fc2(x) # fc2 레이어에 삽입
    return F.log_softmax(x) # fully-connected layer에 넣고 logsoftmax 적용
```

Layer (type)	Output Shape	Param #
Conv2d-1	[-1, 10, 24, 24]	260
MaxPool2d-2	[-1, 10, 12, 12]	0
Conv2d-3	[-1, 20, 8, 8]	5,020
MaxPool2d-4	[-1, 20, 4, 4]	0
Dropout2d-5	[-1, 20, 4, 4]	0
Linear-6	[-1, 100]	32,100
Linear-7	[-1, 10]	1,010
Total params: 38,390		
Trainable params: 38,390		
Non-trainable params: 0		

필터 크기 5*5개

출력 필터 개수 10개

따라서 $10 \times 5 \times 5 + 10(\text{편향}) = 260$

입력채널의 수는 10, 출력 채널의 수는 20

$10 \times 20 \times 5 \times 5 + 20(\text{편향}) = 5020$

입력채널의 수 $20 \times 4 \times 4 = 320$, 출력 채널 = 100

$320 \times 100 + 100(\text{편향}) = 32100$

테스트 진행(경로 설정)

```
img_path_list = []  
for i in range(1,41):  
    root_dir = '/content/drive/MyDrive/Colab Notebooks  
    root_dir += str(i)  
    root_dir += '.jpg'  
    img_path_list.append(root_dir)  
  
print(img_path_list)
```

40개의 이미지 생성후 경로 저장

테스트 진행(실제 데이터)

```
# Load the model from file
model = Net()
PATH_TO_TRAINED_MODEL = 'model.pth'
model.load_state_dict(torch.load(PATH_TO_TRAINED_MODEL, map_location=torch.device('cpu')))
```

저장했던 모듈 불러온 후 평가모드로 전환(gpu 다써서 cpu로 전환)

테스트 진행(실제 데이터)

```
[92] a=['apples','apples','telephone','telephone','subway','subway','tea','tea','elephant','elephant','sunflower','sunflower','  
100] CIFAR100_CLASSES = sorted(['beaver','dolphin','otter','seal','whale', # aquatic mammals  
    'aquarium','fish','flatfish','ray','shark','trout', # fish  
    'orchids','poppies','roses','sunflowers','tulips', # flowers  
    'bottles','bowls','cans','cups','plates', # food containers  
    'apples','mushrooms','oranges','pears','sweet peppers', # fruit and vegetables  
    'clock','computer','keyboard','lamp','telephone','television', # household electrical devices  
    'bed','chair','couch','table','wardrobe', # household furniture  
    'bee','beetle','butterfly','caterpillar','cockroach', # insects  
    'bear','leopard','lion','tiger','wolf', # large carnivores  
    'bridge','castle','house','road','skyscraper', # large man-made outdoor things  
    'cloud','forest','mountain','plain','sea', # large natural outdoor scenes  
    'camel','cattle','chimpanzee','elephant','kangaroo', # large omnivores and herbivores  
    'fox','porcupine','possum','raccoon','skunk', # medium-sized mammals  
    'crab','lobster','snail','spider','worm', # non-insect invertebrates  
    'baby','boy','girl','man','woman', # people  
    'crocodile','dinosaur','lizard','snake','turtle', # reptiles  
    'hamster','mouse','rabbit','shrew','squirrel', # small mammals  
    'maple','oak','palm','pine','willow', # trees  
    'bicycle','bus','motorcycle','pickup truck','train', # vehicles 1  
    'lawn-mower','rocket','streetcar','tank','tractor' # vehicles 2  
])
```

class 설정

테스트 진행(실제 데이터)

```
import torch
from PIL import Image
from torchvision import transforms

# Load the image
for i in range(len(img_path_list)):
    image_path = img_path_list[i]
    image = Image.open(image_path)

    # Define the transformation to apply to the image
    transform = transforms.Compose([
        transforms.Resize((32, 32)), # Resize the image to fit the input shape of your model
        transforms.ToTensor(), # Convert the image to a PyTorch tensor
        transforms.Normalize(mean=[0.5, 0.5, 0.5], std=[0.5, 0.5, 0.5]) # Normalize the image
    ])

    # Apply the transformation to the image
    image_tensor = transform(image)

    # Reshape the tensor to add a batch dimension
    image_tensor = image_tensor.unsqueeze(0)

    # Load your trained model
    model = Net().to(device)
    model.load_state_dict(torch.load("model.pth"))

    # Pass the image through the model to get the predicted class probabilities
    with torch.no_grad():
        model.eval()
        output = model(image_tensor.to(device))
        probabilities = torch.softmax(output, dim=1)

    # Get the predicted class
    predicted_class = torch.argmax(probabilities, dim=1).item()

    print("Predicted class:", CIFAR100_CLASSES[predicted_class], a[i])
```

```
Predicted class: worm apples
Predicted class: worm apples
Predicted class: lamp telephone
Predicted class: worm telephone
Predicted class: telephone subway
Predicted class: worm subway
Predicted class: chair tea
Predicted class: worm tea
Predicted class: worm elephant
Predicted class: worm elephant
Predicted class: lamp sunflower
Predicted class: lamp sunflower
Predicted class: worm house
Predicted class: chair house
Predicted class: worm sea
Predicted class: worm sea
Predicted class: lamp cycle
Predicted class: worm cycle
Predicted class: worm flower
Predicted class: worm flower
Predicted class: lamp tv
Predicted class: worm tv
Predicted class: worm sneak
Predicted class: chair sneak
Predicted class: kangaroo mountain
Predicted class: worm mountain
Predicted class: worm people
Predicted class: chair people
Predicted class: worm skunk
Predicted class: worm skunk
Predicted class: worm butterfly
Predicted class: worm butterfly
Predicted class: lamp chair
Predicted class: oranges chair
Predicted class: worm hamster
Predicted class: chair hamster
Predicted class: worm tree
Predicted class: worm tree
Predicted class: oranges oranges
Predicted class: chair oranges
```

예상값과 정답, 그리고 output출력
정확도 : 약 5%정도